과제 1 · 기존 Base AI Agent 개선

운영 장애 조사 에이전트 개선

서비스와 장애 증상을 입력하면
지표 · 로그 · 대응 매뉴얼로 진단과 권고를 제공합니다 .

추가 · 수정 : 잘못된 시스템 조회 방지 · 설정 외부화

RAG · 전문 조사 · 요약 메모리 · 오프라인 LLM Judge

재사용 기반 : FastAPI · Vue · 메인 LangGraph · MCP 연결

모니터링 · 로그는 합성 데이터입니다 . 조치는 실행하지 않은 권고입니다 .

G087 신형섭

G087 신형섭

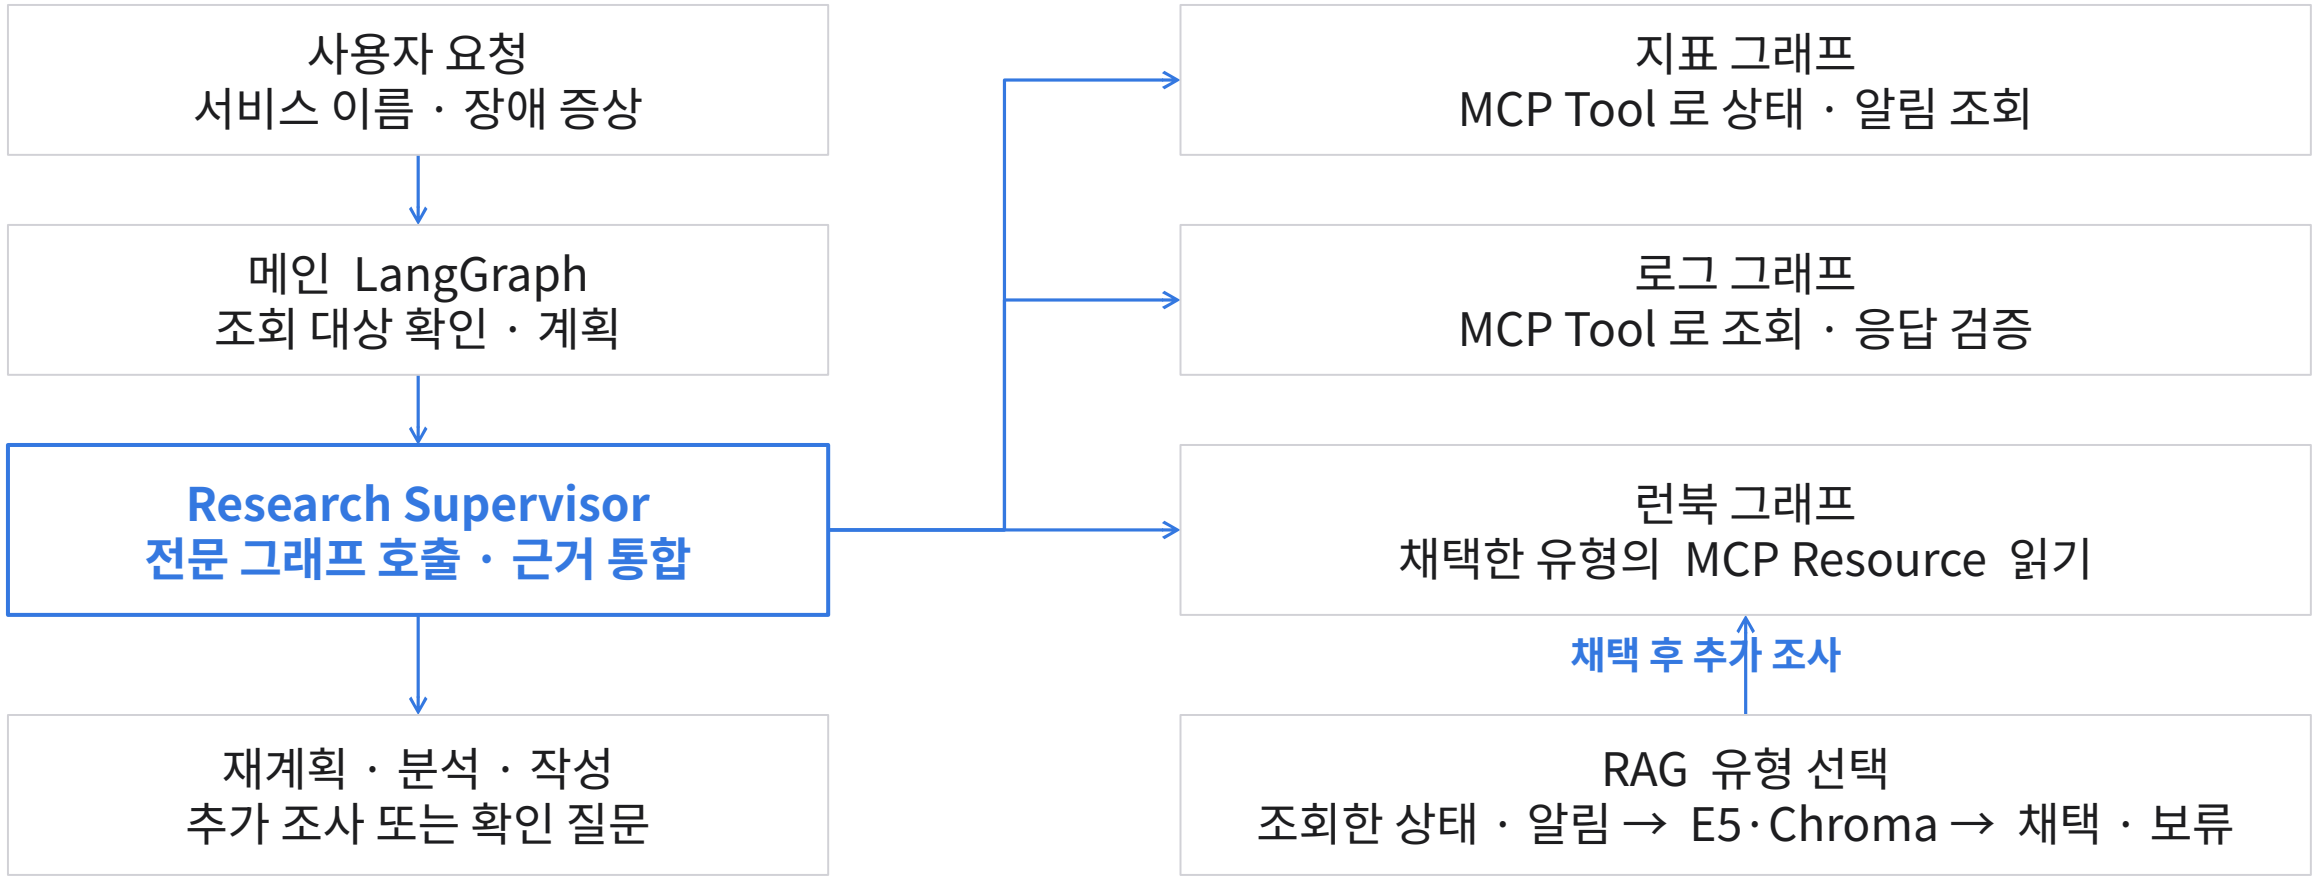
기존 서비스 문제점과 개선 사항

기존 서비스의 문제	적용한 개선
영어 키워드가 한국어 증상을 놓침	E5·Chroma 의미 검색 저신뢰 결과는 보류
기존 조사 흐름의 출처별 처리 · 검증 확장 필요	지표 · 로그 · 런북 전문 Subgraph 출처 검증과 부분 실패 처리
최근 대화만 입력하면 과거 사실이 누락됨	원문 보존형 증분 요약 메모리 사실 회수와 토큰 사용량 검증

함께 개선한 부분

잘못된 시스템 조회 방지 · 설정 외부화 / 코드 검사와 오프라인 LLM Judge

개선 후 아키텍처

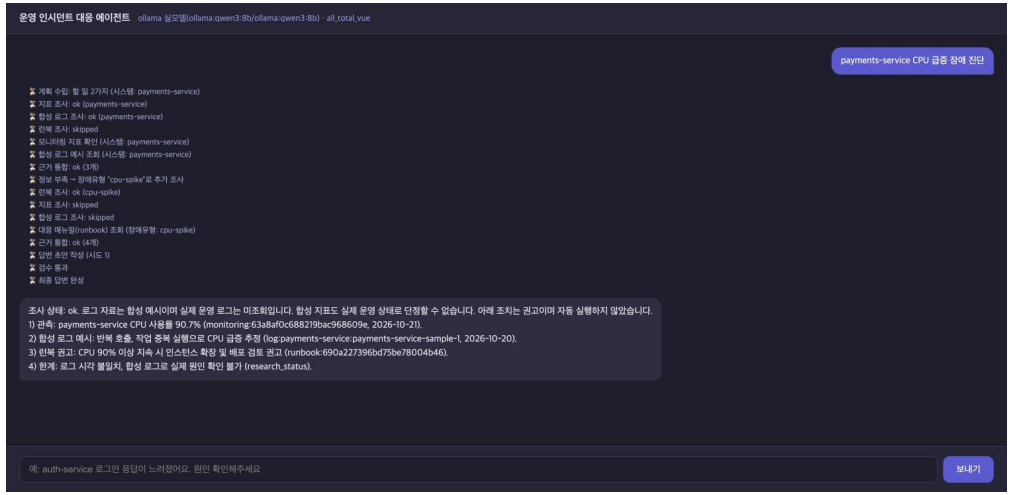


요약 메모리 : 대화 문맥 보완 / 오프라인 Judge: 저장 답변 평가

G087 신형섭

최종 실행과 기능 개선 전후

기능별 동일 조건 비교 · 모델 교체 실험과 구분



최종 실행 예시 · 실제 Qwen 8B
합성 근거 · 출처 · 한계 · 미실행 권고

검증 항목	개선 전	개선 후
잘못된 대상 조회	2/2	**0/2**
한국어 런북 정답	1/6	**4/6**
확보한 출처 종류	2/3	**3/3**
과거 사실 회수	0/5	**5/5**

요약 실험 총 토큰 +147.8%
다른 Qwen 대화 이력에서는 회상 실패

각 행은 별도 실험 . 대상 ·RAG· 출처는 fake 답변 (검색은 실제 E5), 기억은 동일 Qwen 8B.

Graph: 조사와 재계획의 연결

현재 대상 확인 → 계획 → 지표 · 로그 조사 → 재계획

```
g.add_edge("gate", "research")
g.add_edge("research", "replan_check")
g.add_conditional_edges(
    "replan_check", _after_replan_check,
    {"analysis": "analysis",
     "research": "research",
     "retrieval_clarification": "retrieval_clarification"},
)
```

충분 : 분석 런북 부족 : 추가 조사 검색 보류 : 확인 질문

추가한 지표 · 로그 · 런북 StateGraph 를 SupervisorDeps 로 주입 . 부분 실패 시 성공한 근거를 보존 .

MCP: 로그 Tool 과 런북 Resource

Tool: 기능 호출 / get_recent_logs(system_name, limit=20)

```
return await deps.mcp.call_tool(
    "get_recent_logs",
    {"system_name": state["target"], "limit": 20},
)
```

Resource: 문서 읽기 / 유형 선택 후 런북 본문 조회

```
server, template = await deps.mcp.find_resource_template(
    "get_incident_runbook"
)
uri = template.format(incident_type=target)
body = await deps.mcp.read_resource(uri, server=server)
```

응답의 대상 · 시각 · 출처를 검증합니다 . 기존 세션 · 탐색 · 잠금 재사용 . 실제 MCP I/O 는 직렬입니다 .

RAG: 의미 검색과 채택 · 보류

조회한 상태 · 알림 → E5 임베딩 → Chroma Top 3

```
def decide(candidates: list[dict], threshold: float, margin: float) -> bool:
    return bool(
        candidates
        and candidates[0]["score"] >= threshold
        and (
            len(candidates) == 1
            or candidates[0]["score"] - candidates[1]["score"] >= margin
        )
    )
```

채택 : 1 위 점수 ≥ 0.8 그리고 1·2 위 차이 ≥ 0.01

채택 후 MCP 본문 조회 / 미달 시 추가 증상 요청

런북 6 개를 문서 단위로 임베딩 . 유사도는 확률이 아닙니다 . 채택한 본문은 MCP 로 읽습니다 .

한계 및 향후 개선

확인한 한계	향후 개선
요약 총 토큰 1,247 → 3,090 147.8% 증가	요약 호출 · 추가 문맥 비용 평가
다른 Qwen 이력에서 회상 실패 허위 근거 ID 로 요약 거부 ·fallback	사실 · 근거 ID 보존 검증 기억 실패 사례 확대
CPU 답변 Judge 점수는 모두 4/4 잘못된 대상 조회 등 정책 차이를 놓침	대상 · 수치 · 출처 코드 검사 강화 독립 평가 집합 확대
현재 지표 · 로그는 합성 데이터	실제 운영 로그 연동

구조를 나누는 것과 답변의 신뢰성을 높이는 것은 각각 검증해야 했습니다

G087 신형섭

부록 · 같은 CPU 증상의 런북 선택 비교

동일 질문 : payments-service 장애 진단 / CPU 96.2% / 프로세서 사용률 급증

Before · 영어 키워드 / DB 장애 매뉴얼 선택

'payments-service 장애 진단' 진단 결과: 1) 모니터링: payments-service 상태=degraded, CPU 96.2% (알림 1건) 2) 표준 절차: 'Runbook: DB Down 대응 절차'에 따라 커넥션 풀/리플리케이션 상태를 점검하고 필요 시 failover 노드로 전환한다. 서비스 정상화 확인 후 원인 분석과 재발 방지 대책을 문서화한다. 3) 정상화 확인 후 원인 분석과 재발 방지 대책을 문서화하세요.

After · 의미 검색 RAG / CPU 급증 매뉴얼 선택

'payments-service 장애 진단' 진단 결과: 1) 모니터링: payments-service 상태=degraded, CPU 96.2% (알림 1건) 2) 표준 절차: 'Runbook: CPU 급증 대응 절차'에 따라 반복 호출, 배치 작업 중복 실행 같은 특정 요청 패턴이 원인인지 최근 로그에서 확인한다. CPU가 90%를 넘고 지속되면 해당 인스턴스를 오토스케일링 그룹에서 한 대 더 띄워 부하를 분산한다. 3) 정상화 확인 후 원인 분석과 재발 방지 대책을 문서화하세요.

별도 한국어 6 문항 정답 1/6 → 4/6. 화면은 fake 답변 · 실제 E5, 평가 집합과 별개 .

부록 · 변경별 동일 조건 수치

변경	통제 조건	Before / After
대상 정책	fake· 운영 질의 2 개	**허용 외 조회 2/2 → 0/2**
RAG	알려진 유형 6 개	**정답 1/6 → 4/6**
전문 조사	CPU 1 사례 · 출처 3 종	**출처 2/3 → 3/3**
요약 기억	12 턴 ·8B· 고정 chat	**회수 0/5 → 5/5**

각 행은 별도 실험 . 단계별 재생 지연은 미계측이며 백엔드 비교와 구분합니다 .

G087 신형섭

부록 · 메모리와 Judge 의 한계

항목	확인 결과	해석
메모리 총 토큰	1,247 → 3,090	147.8% 증가
Qwen 기억 실패	허위 근거 ID	요약 거부 후 fallback
오프라인 Judge	38/39 scored	계측 불일치 1 행 제외
CPU groundedness	모든 단계 4/4	정책 차이 구분 못함

사람 확인 4 범주 방향 일치 : Qwen·OpenAI 모두 4/4. 일반 평가 정확도는 미입증 .

부록 · 기술 적용과 개선 포인트

Multi-Agent	전문 compiled subgraph · 부분 실패 계약
MCP · 의존성 주입	기존 세션 재사용 · 로그 Tool · deps 확장
RAG · 모듈화	E5 · Chroma 검색 · 조사 · 요약 책임 분리
LangSmith · 단위 테스트	trace 확장 · SSE 9 개 · OpenAI 응답 6 개
다음 개선	기억 사례 확대 · 실제 로그 · 동기 호출 취소

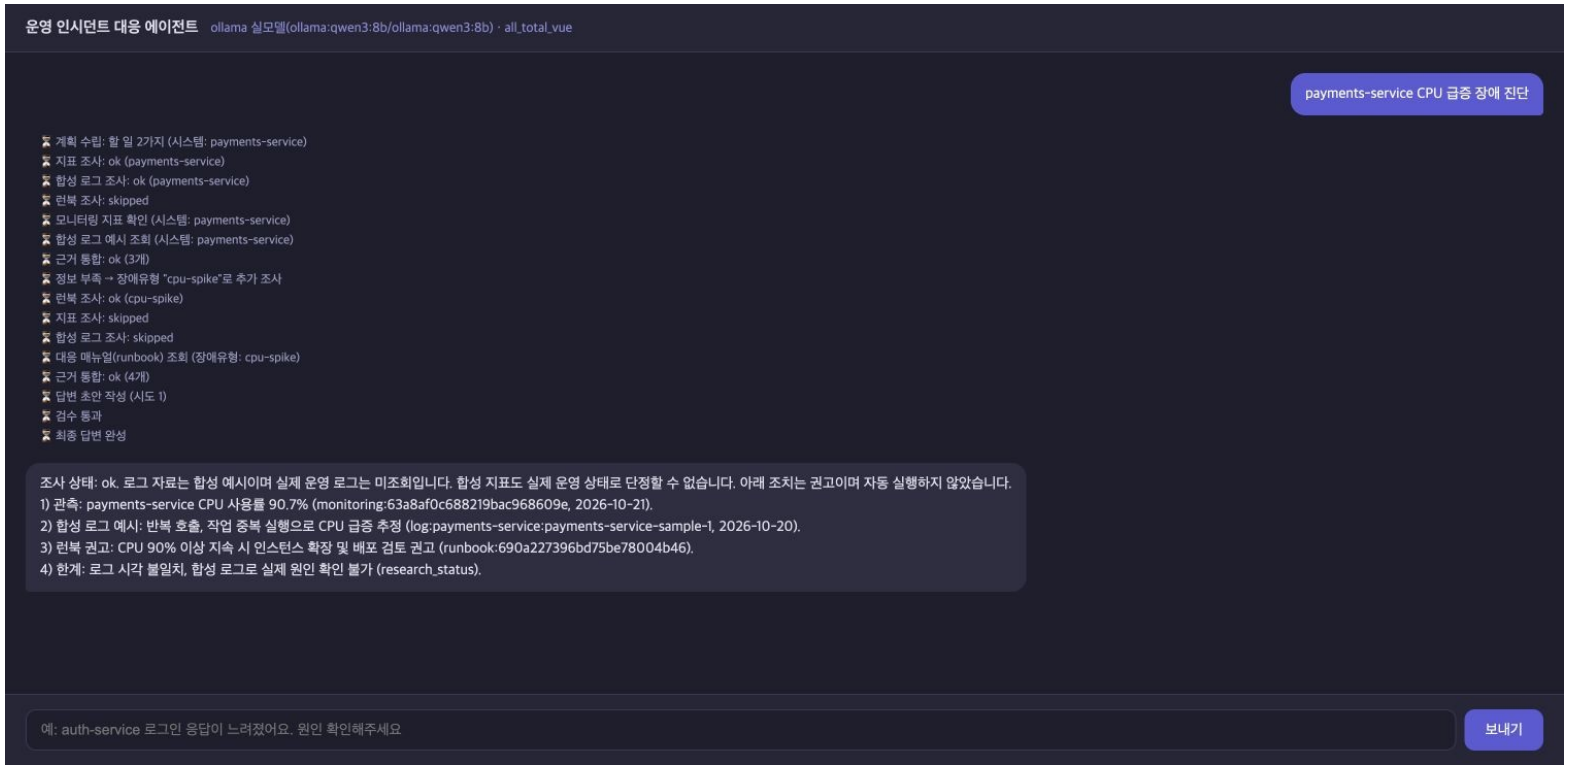
전체 213 PASS · 13 XFAIL / 공개 116 PASS · 5 XFAIL. MCP I/O 는 직렬 , 부하 시험 미실시 .

부록 · Qwen 과 OpenAI 교차 검증

같은 최종 코드 비교	Qwen 8B / 8B	OpenAI mini / 4o
인사 HTTP p50	1.12 초	**1.70 초**
CPU HTTP p50	12.50 초	**4.70 초**
이름 회상	0/10	**10/10**
측정 40 요청 API 비용	로컬 청구 $0	**$0.06398 추정**

96 요청 중 측정 80 건. 지연 n=5, 회상은 한 이력 반복. 실제 청구 · 전력 비용 미측정.

부록 · 최종 Qwen 실행 화면



실제 Qwen 8B · strict/RAG/multi/summary. 근거는 합성 데이터이며 조치는 미실행 권고 .